

暨南大学本科实验报告专用纸

课程名称 计算机视觉实验 指导教师 赵乘骥 成绩
实验项目 Transformer位置编码与RoPE原理实验 实验项目编号 10
实验地点 教 108 学院 国际能源学院 专业 自动化
学生姓名 曹瑞 学号 2023104666 实验时间 2026 年 6 月 5 日

一、实验目的

- 理解Transformer模型中位置编码（Position Encoding）的作用。
- 掌握Sinusoidal Position Encoding（正弦位置编码）的计算方法与实现过程。
- 理解二维向量旋转的数学原理，为学习RoPE奠定基础。
- 掌握Rotary Position Embedding（RoPE）的位置编码机制。
- 学习RoPE与传统Embedding+Position方法之间的区别。
- 验证RoPE具有天然相对位置编码能力的性质。
- 理解当前主流大语言模型（LLaMA、Qwen、DeepSeek等）采用RoPE的原因。

二、实验环境

1. 硬件环境

内存：16GB

GPU：CPU运行

2. 软件环境

Windows 11

WSL Ubuntu 24.04

VSCode

Python 3.12

3. 使用的Python库

numpy

matplotlib

安装命令：

pip install numpy matplotlib

三、实验原理

1. Transformer为什么需要位置编码

与RNN和CNN不同，Transformer结构完全依赖Attention机制。

Attention本身只能计算不同Token之间的相关性，而无法感知序列顺序信息。

2. Sinusoidal Position Encoding

Transformer原论文采用正弦位置编码。

其计算公式为：

$$PE(pos, 2i) = \sin(pos/10000^{(2i/d)})$$

$$PE(pos, 2i+1) = \cos(pos/10000^{(2i/d)})$$

其中：

- pos 表示位置
- i 表示维度索引
- d 表示Embedding维度

通过不同频率的正弦和余弦函数构造位置向量。

3. Rotary Position Embedding (RoPE)

RoPE的核心思想是：

不再将位置向量直接加到Embedding上，而是通过旋转矩阵作用于向量。

二维旋转矩阵：

$$R(\theta) =$$

$$\begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}$$

$$\begin{bmatrix} \sin\theta & \cos\theta \end{bmatrix}$$

对于高维向量：

将相邻两个维度组成二维向量对，并进行不同角度旋转。

这样能够使Attention天然获得相对位置信息。

四、实验内容

本实验共完成六个部分。

1、Sinusoidal Position Encoding实现

实现长度100、维度64的位置编码矩阵。

生成位置编码热力图。

实验结果保存：sinusoidal_encoding.png

2、二维向量旋转实验

构造二维向量： $v=(1,0)$ 旋转角度： $\theta=45^\circ$

观察旋转前后向量变化。

实验结果保存：vector_rotation.png

3、RoPE位置编码实现

实现高维RoPE编码。

对64维向量进行位置旋转。

观察不同位置下编码结果变化。

实验结果保存: rope_encoding.png

4、E+Pos与RoPE对比实验

比较两种位置编码方式:

(1) Embedding + Position

(2) Rotary Position Embedding

观察编码分布差异。

实验结果保存: epos_vs_rope.png

5、RoPE相对位置性质验证

固定Query位置: $\text{Position} = 10$

改变Key位置: $\text{Position} = 10 + \Delta$

计算Attention Score变化情况。

实验结果保存: rope_relative_property.png

6、Attention Score比较

分别计算:

- E+Pos Attention Score

- RoPE Attention Score

观察不同位置下Attention变化规律。

实验结果保存: attention_score_comparison.png

五、实验结果分析

本实验成功完成了Transformer位置编码与RoPE原理的验证, 程序运行结束后输出:

Lab10实验完成, 结果保存在./lab10/results

共生成6幅实验结果图:

1. sinusoidal_encoding.png

2. vector_rotation.png

3. rope_encoding.png


4. epos_vs_rope.png

5. rope_relative_property.png

6. attention_score_comparison.png

（一）Sinusoidal Position Encoding实验结果与分析

实验生成了长度为100、维度为64的正弦位置编码热力图（sinusoidal_encoding.png）。



从图中可以观察到：

- 不同维度呈现不同频率的周期变化；
- 低维区域变化较快，高维区域变化较慢；
- 整体呈现规律性的波纹结构。

这说明正弦位置编码利用不同频率的正弦和余弦函数，为每一个位置生成唯一的位置表示，从而使Transformer能够获得序列位置信息。


同时，由于位置编码具有连续变化特性，相邻位置之间保持一定相关性，有利于模型学习序列结构。

（二）二维向量旋转实验结果与分析

实验构造二维向量：

$$\mathbf{v}=(1,0)$$

并进行了45°旋转，生成图像 vector_rotation.png。



从结果可以看出：


- 向量长度保持不变；
- 向量方向发生改变；
- 旋转前后仅改变角度信息。

这表明旋转矩阵能够在不破坏原始信息的情况下引入新的位置信息。

RoPE正是利用这一思想，将位置信息编码为向量的旋转角度，而不是直接叠加到Embedding上。

（三）RoPE位置编码实验结果与分析

实验实现了RoPE编码，并生成热力图 rope_encoding.png。



从图中可以观察到：

- 不同位置对应不同的旋转结果；
- 编码随位置变化呈现连续变化趋势；
- 不同维度具有不同旋转频率。

说明RoPE能够将位置信息映射到向量空间中的旋转角度上。

与传统位置编码相比，RoPE并未直接修改Embedding数值，而是通过旋转操作改变向量方向，因此能够更好地保留原始语义信息。

（四）E+Pos与RoPE对比实验结果与分析

实验比较了两种位置编码方法：

1. Embedding + Position (E+Pos)

其计算方式为：

Embedding + Position Encoding

特点：


- 实现简单；
- 位置向量直接与Embedding相加；
- 内容信息与位置信息混合。

2. Rotary Position Embedding (RoPE)

特点：

- 不采用加法；
- 利用旋转矩阵编码位置；
- 保持Embedding结构完整。

从实验图像 epos_vs_rope.png



可以观察到：

E+Pos方法会改变Embedding数值分布，而**RoPE**方法则保持向量结构连续变化。


因此**RoPE**能够更好地区分内容信息与位置信息，具有更好的理论基础。

（五）RoPE相对位置性质验证结果与分析

实验固定：Query Position = 10

不断改变：Key Position = 10 + Δ

得到图像 rope_relative_property.png。



结果表明：

Attention Score主要随着位置差 Δ 变化而变化，而不是绝对位置本身。

即：Attention(Q_m, K_n)

主要受到： $m - n$ 影响。

这说明**RoPE**天然具备相对位置编码能力。


传统位置编码需要额外设计相对位置机制，而RoPE通过旋转结构即可自动获得这一性质。

（六）Attention Score比较实验结果与分析

实验分别计算：

- E+Pos Attention Score
- RoPE Attention Score

得到图像 attention_score_comparison.png。



从结果可以观察到：

E+Pos方法

- Attention得分波动较大；
- 位置信息与内容信息耦合明显；
- 长距离位置关系表达能力有限。

RoPE方法

- Attention变化更加平滑；
- 相对位置关系表达更加自然；
- 长距离依赖建模能力更强。

实验结果验证了RoPE在Transformer中的设计优势。

由于Attention计算过程中已经包含相对位置信息，因此模型能够更有效地处理长文本任务。

六、问题回答

1. Transformer 为什么需要位置编码？

Transformer与RNN不同，不具备天然处理序列顺序信息的能力。Transformer中的Self-Attention机制仅根据输入向量之间的相似度计算注意力权重，而无法区分词语在序列中的先后顺序。

例如：

我喜欢学习
学习喜欢我

这两个句子包含相同的词语，但顺序不同，表达的含义也不同。如果没有位置编码，Transformer会将它们视为相同的输入。因此，需要引入位置编码（Position Encoding）来向模型提供位置信息，使模型能够感知序列顺序，从而正确理解语义关系。

2. 传统 Sinusoidal Position Encoding 是如何生成的？

Transformer原论文采用正弦位置编码（Sinusoidal Position Encoding）。

其核心思想是利用不同频率的正弦函数和余弦函数生成位置向量：

偶数维： $PE(pos, 2i) = \sin(pos/10000^{(2i/d)})$

奇数维： $PE(pos, 2i+1) = \cos(pos/10000^{(2i/d)})$

其中：

- pos 表示当前位置；
- i 表示维度索引；
- d 表示向量维度。

通过不同频率的正弦和余弦组合，每个位置都对应一个唯一的位置表示。同时，相邻位置之间具有连续变化特性，有利于模型学习序列结构。

3. E + Pos 的位置注入方式为什么有“内容和位置混合”的问题？

传统方法通常采用：Embedding + Position Encoding

即： $x' = x + p$

其中：

- x 表示词向量（内容信息）；
- p 表示位置向量（位置信息）。

这种做法虽然简单，但会导致内容信息与位置信息直接混合到同一个向量中。

模型在后续计算时无法明确区分：

- 哪部分来自语义内容；
- 哪部分来自位置信息。

因此会带来以下问题：

1. 内容与位置耦合；
2. 长序列泛化能力有限；
3. 相对位置关系表达能力不足；
4. Attention难以直接利用位置信息。

4. RoPE 不是加法，而是旋转

RoPE（Rotary Position Embedding）采用了一种全新的位置编码方式。

它不再将位置向量加到Embedding上，而是将位置表示为旋转操作。

对于二维向量： (x_1, x_2)

RoPE使用旋转矩阵：

$$\begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}$$

进行旋转变换。

对于高维向量，则将相邻两个维度组成二维向量对，分别进行不同角度的旋转。

这种方法不会改变向量长度，而是通过改变向量方向来编码位置信息，因此能够更好地保留原始语义信息。

5. RoPE 作用在 Q 和 K 上

在Transformer中，RoPE并不是作用于输入Embedding，而是作用于Attention中的：

Query (Q) Key (K)

即： $Q \rightarrow \text{RoPE}(Q)$ $K \rightarrow \text{RoPE}(K)$

然后再计算Attention分数：

$\text{Attention Score} = Q \cdot K$

Value (V) 通常不进行旋转。

这样设计的原因是：

位置信息主要影响注意力权重计算，而不需要影响最终传递的内容信息，因此只需要对Q和K进行位置编码即可。

6. RoPE 的点积天然包含相对位置

RoPE最重要的特点之一是：

经过旋转后的Q和K进行点积计算时，其结果自动包含位置信息。

设： Q_m 表示位置m上的Query， K_n 表示位置n上的Key。

经过RoPE旋转后： $\text{RoPE}(Q_m) \cdot \text{RoPE}(K_n)$

最终结果不仅与向量本身有关，还与 $(m - n)$ 有关。

也就是说，Attention分数天然编码了两个Token之间的相对距离。

因此无需额外设计复杂的相对位置编码机制。

7. Attention Score里的相对位置关系为什么可以通过旋转结构自然出现？

RoPE本质上将位置信息表示为旋转角度。

对于不同位置：

位置 $m \rightarrow$ 旋转 θ_m

位置 $n \rightarrow$ 旋转 θ_n

当Q和K进行点积时： $\text{RoPE}(Q_m) \cdot \text{RoPE}(K_n)$

根据旋转矩阵性质，可以推导出：

结果只与： $\theta_m - \theta_n$ 有关。

而： $\theta_m - \theta_n$ 正对应于两个Token之间的相对位置差。

因此：Attention Score天然能够表达：谁在前；谁在后；相距多远。无需额外引入相对位置编码参数。

这也是RoPE能够在长文本建模中取得优异效果的重要原因。