

暨南大学本科实验报告专用纸

课程名称 计算机视觉实验 指导教师 赵乘骥 成绩
实验项目：基于 MediaPipe Pose 与骨架序列 Transformer 的羽毛球击球动作识别
实验项目编号 11
实验地点 教 108 学院 国际能源学院 专业 自动化
学生姓名 曹瑞 学号 2023104666 实验时间 2026 年 6 月 12 日

一、实验目的

- 理解视频动作识别任务如何转化为骨架时间序列分类任务。
- 掌握 MediaPipe Pose 提取人体姿态关键点的方法。
- 掌握将不同长度视频统一转换为固定长度骨架序列的方法。
- 学习 Transformer Encoder 在时序动作识别中的应用。
- 完成视频预处理、模型训练、测试评估和单样本推理全过程。
- 理解骨架动作识别技术在体育视频分析中的应用价值与局限性。

二、实验环境

项目	配置
操作系统	Ubuntu 24.04 (WSL)
开发工具	Visual Studio Code
编程语言	Python 3.12
深度学习框架	PyTorch
姿态估计工具	MediaPipe
图像处理库	OpenCV
数据处理库	NumPy
机器学习库	Scikit-Learn
运行设备	CPU

三、实验原理

3.1 实验背景

羽毛球击球动作具有明显的时间动态特征，包括引拍、挥拍、击球、收拍和回位等多个阶段。传统的视频动作识别通常直接输入原始视频帧进行训练，但这种方法存在以下问题：

- 视频数据维度高；
- 计算量大；
- 对 GPU 显存要求高；
- 训练时间长。

因此本实验采用人体骨架序列代替原始视频。

首先利用 MediaPipe Pose 提取人体关键点，然后利用 Transformer Encoder 学习人体动作随时间变化的规律，实现羽毛球动作分类。

3.2 MediaPipe Pose

MediaPipe Pose 可以检测人体 33 个关键点。

每个关键点包含：

- x 坐标
- y 坐标
- z 坐标
- visibility（可见度）


因此每一帧的骨架特征维度为：

$$33 \times 4 = 132$$

即：Frame Feature = 132维

3.3 骨架序列表示

对于一段视频：



实验中统一采样为：T = 30

因此每个视频样本表示为：


$$X_i \in R^{30 \times 132}$$

即：30帧 × 132维特征

其中每一帧骨架状态视为一个 Transformer Token。

3.4 Skeleton Transformer

模型结构如下：



实验参数设置如下：

参数	数值
input_dim	132
d_model	128
nhead	4
num_layers	2
dim_feedforward	256
dropout	0.1
num_classes	6

四、数据集介绍

4.1 数据集来源

4.2 动作类别

数据集共包含 6 类羽毛球动作。

标签	类别
0	Forehand Drive
1	Forehand Lift
2	Forehand Net Shot
3	Forehand Clear
4	Backhand Drive
5	Backhand Net Shot

4.3 数据统计

实验实际统计结果：

类别	视频数量
backhand_drive	111
backhand_net_shot	168
forehand_clear	119
forehand_drive	159
forehand_lift	174
forehand_net_shot	105

总视频数：836

五、实验内容

5.1 数据预处理

按照实验要求完成以下步骤：

（1）遍历全部视频

使用 OpenCV 读取数据集中所有视频文件。

支持格式：

.mp4
.avi
.mov
.mkv

（2）关键点提取

利用 MediaPipe Pose 提取人体关键点。

每帧输出：33个关键点

每个关键点：

x, y, z, visibility

（3）构建骨架特征

每帧展开为： $33 \times 4 = 132$ 维特征向量。

（4）时间重采样

由于视频长度不同，统一重采样为：30帧

最终样本格式：[30,132]

（5）训练测试集划分

按照：Train : Test = 8 : 2划分数据。

得到：

$X_{train} = (668, 30, 132)$

$X_{test} = (168, 30, 132)$

（6）保存数据

保存以下文件：

X_train.npy
y_train.npy


X_test.npy
y_test.npy

label_map.json

5.2 骨架可视化

随机选择一个视频样本，绘制人体骨架结构图。

结果保存为：该图展示了 MediaPipe 提取的人体关键点连接关系。



5.3 Transformer训练


训练配置:

项目	设置
Optimizer	Adam
Loss Function	CrossEntropyLoss
Batch Size	32
Learning Rate	0.001
Epochs	20

训练过程中记录:

- Loss曲线
- Accuracy曲线

生成:



六、实验结果分析

6.1 训练过程分析

训练日志显示：

Epoch 1:
Loss=1.7849
Acc=0.2021

...

Epoch 20:
Loss=0.6792
Acc=0.7425

可以观察到：

- Loss 持续下降；
- Accuracy 持续提高；
- 模型成功学习到骨架序列中的动作特征。

最终训练准确率达到：74.25%

说明模型已经较好拟合训练数据。

6.2 测试结果

最终测试结果：Accuracy = 54.76%

即：

$Accuracy = 54.76\%$

相比随机猜测：1 / 6 = 16.67%有明显提升。

说明 Transformer 已经能够学习不同击球动作的时间模式。

6.3 分类报告分析

分类结果如下：

类别	Precision	Recall	F1
forehand_drive	0.61	0.53	0.57
forehand_lift	0.60	0.74	0.67
forehand_net_shot	0.75	0.43	0.55
forehand_clear	0.35	0.25	0.29
backhand_drive	0.29	0.45	0.36
backhand_net_shot	0.71	0.71	0.71

其中：

识别效果最好Backhand Net Shot

F1-score: 0.71

说明该动作具有较明显的人体运动特征。

识别效果较差Forehand Clear


F1-score: 0.29

原因在于:

- 动作幅度与其他动作相似;
- 骨架信息无法反映羽毛球飞行轨迹;
- 骨架特征存在信息缺失。

6.4 混淆矩阵分析

生成混淆矩阵: confusion_matrix.png



从混淆矩阵可以观察到:

- 正手挑球与正手高远球容易混淆;
- 正手平抽与反手平抽存在交叉误判;
- 网前球识别效果较好。

说明部分动作之间的身体姿态较为接近。

6.5 单样本推理结果

随机选取测试样本进行推理。

输出结果:

Predicted class:
forehand_lift

Confidence:0.6607

即:

预测类别: Forehand Lift (正手挑球)

置信度: 66.07%

说明模型能够完成实际动作识别任务。

七、问题回答

7.1 为什么不直接使用 Video Transformer?

直接输入原始视频存在以下问题：

1. 视频数据维度极高；
2. 训练成本大；
3. GPU显存需求高；
4. 需要更多训练样本。

本实验采用骨架序列：

视频

↓

关键点

↓

Transformer

仅保留人体动作信息。大幅降低计算量。因此更适合课程实验环境。

7.2 为什么准确率只有54.76%?

主要原因包括：

（1）骨架信息存在缺失

MediaPipe只能获取：人体关键点

无法获取：

羽毛球轨迹、球拍轨迹

而这些信息对于羽毛球动作识别非常重要。

（2）类别之间相似度高

例如：

Forehand Lift、Forehand Clear

动作过程非常接近。

仅依靠人体骨架难以完全区分。

（3）数据规模有限

实验数据仅：836个视频

对于 Transformer 来说数据量偏小。

八、实验总结

本实验基于 MediaPipe Pose 与 Transformer Encoder 完成了羽毛球击球动作识别系统的设计与实现。

首先利用 MediaPipe 从视频中提取人体 33 个关键点，并构建 30×132 维骨架时间序列；随后采用 Skeleton Transformer 对动作序列进行建模，实现 6 类羽毛球动作分类；最后完成模型训练、测试评估和单样本推理。

实验共处理 836 个视频样本，生成训练集和测试集骨架数据，最终获得 54.76% 的测试准确率，并成功实现

动作类别预测与置信度输出。

实验结果表明，Transformer 能够有效学习人体骨架序列中的时间动态特征，在不依赖原始视频像素的情况下完成羽毛球动作识别任务。虽然受限于骨架信息缺失和数据规模等因素，模型准确率仍有提升空间，但已经验证了骨架序列 Transformer 在体育动作分析中的可行性和应用价值。